

Comparação de Algoritmos de Aprendizado de Máquina na Predição de Interações Medicamentosas usando DrugBank

Experiência Criativa: Projeto Transformador
Bacharelado em Ciência da Computação – PUCPR

Turma B – Equipe 14

Crystofer Samuel, Murilo Pedrazzani, Ricardo Makino, Ricardo Vianna
{email1, murilo.pedrazzani, email3, email4}@pucpr.edu.br

I. DESCRIÇÃO, CONTEXTUALIZAÇÃO E ESCOPO DO PROJETO

A segurança do paciente é uma preocupação central na saúde moderna, especialmente no contexto de interações medicamentosas adversas (IMAs), que podem resultar na redução da eficácia terapêutica, aumento da toxicidade ou eventos clínicos graves. Esse problema é intensificado em cenários de polifarmácia, nos quais múltiplos medicamentos são administrados simultaneamente, elevando significativamente o risco de interações indesejadas.

Abordagens computacionais têm sido amplamente utilizadas para apoiar a tomada de decisão clínica, reduzindo erros e melhorando a qualidade do atendimento [2]. O avanço de bases biomédicas, como o DrugBank [1], permite a análise em larga escala de interações medicamentosas, oferecendo dados estruturados e descrições textuais detalhadas.

Técnicas de aprendizado de máquina têm apresentado bons resultados na predição dessas interações [3]. Algoritmos como Random Forest, Support Vector Machine (SVM) e XGBoost destacam-se por sua capacidade de lidar com dados complexos, alta dimensionalidade e relações não lineares.

Entretanto, desafios como o desbalanceamento de classes impactam significativamente o desempenho dos modelos, especialmente na identificação de interações graves, que são menos frequentes porém mais críticas [4]. Trabalhos recentes também exploram modelos baseados em linguagem natural e deep learning [5], evidenciando a evolução da área.

Este trabalho tem como objetivo comparar o desempenho dos algoritmos Random Forest, SVM e XGBoost na classificação da gravidade das interações medicamentosas, considerando métricas robustas e o impacto do desbalanceamento de dados.

Questão de pesquisa: Qual algoritmo apresenta melhor desempenho na classificação da gravidade das interações medicamentosas utilizando dados do DrugBank?




Figura 1. Visão geral do processo de predição de interações medicamentosas.

II. MATERIAIS E MÉTODOS

A. Dataset

O dataset será extraído do DrugBank [1], contendo pares de medicamentos e descrições textuais de suas interações. Trata-se de uma base amplamente utilizada na literatura científica, contendo informações relevantes para estudos de farmacologia computacional.




Figura 2. Fluxo metodológico do projeto.

B. Pré-processamento

Será realizada limpeza dos dados, incluindo remoção de duplicatas, padronização textual, remoção de caracteres especiais e eliminação de inconsistências. Pares invertidos (A–B e B–A) serão removidos para evitar redundância.

Os dados serão estruturados como:

drug A [SEP] drug B

As interações serão classificadas em três níveis: leve, moderado e grave, com base em padrões linguísticos presentes nas descrições.

C. Representação dos Dados

Será utilizada a técnica TF-IDF para converter os textos em vetores numéricos. Essa abordagem permite destacar termos relevantes e reduzir o impacto de palavras frequentes, sendo amplamente utilizada em tarefas de classificação textual.

D. Modelos de Aprendizado de Máquina

Serão utilizados Random Forest, SVM e XGBoost.

O Random Forest reduz overfitting por meio de ensembles. O SVM é eficiente em espaços de alta dimensionalidade. O XGBoost utiliza boosting otimizado, sendo altamente competitivo em problemas supervisionados.

drugbank_drug_name	interacting_drug_name	interaction_descripticlabel
DB00001 lepirudin	DB06605 apixaban	apixaban may increasmoderado
DB00001 lepirudin	DB06695 dabigatran etexilate	dabigatran etexilate nmoderado
DB00001 lepirudin	DB01254 dasatinib	the risk or severity of tgrave
DB00001 lepirudin	DB01609 deferasirox	the risk or severity of tgrave
DB00001 lepirudin	DB01586 ursodeoxycholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB02123 glycochenodeoxycholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB02659 cholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB02691 glycocholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB03619 deoxycholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB04348 taurocholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB05990 obeticholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB06777 chenodeoxycholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB08833 taurochenodeoxycholic acid	the risk or severity of tgrave
DB00001 lepirudin	DB08834 tauroursodeoxycholic acid	the risk or severity of tgrave
DB00807 propracaine	DB00828 fosfomycin	the risk or severity of rmoderado
DB00807 propracaine	DB00833 cefaclor	the risk or severity of rmoderado
DB00807 propracaine	DB00845 cefazolin	the risk or severity of rmoderado
DB00807 propracaine	DB00877 sirolimus	the risk or severity of rmoderado
DB00807 propracaine	DB00895 benzylpenicilloyl polylysine	the risk or severity of rmoderado
DB00807 propracaine	DB00911 tinidazole	the risk or severity of rmoderado
DB00807 propracaine	DB00916 metronidazole	the risk or severity of rmoderado
DB00807 propracaine	DB00919 spectinomycin	the risk or severity of rmoderado
DB00807 propracaine	DB00923 ceforanide	the risk or severity of rmoderado
DB00807 propracaine	DB00931 metacycline	the risk or severity of rmoderado
DB00807 propracaine	DB00948 mezlocillin	the risk or severity of rmoderado
DB00807 propracaine	DB00951 isoniazid	the risk or severity of rmoderado
DB00807 propracaine	DB00954 dirithromycin	the risk or severity of rmoderado
DB00807 propracaine	DB00955 netilmicin	the risk or severity of rmoderado
DB00807 propracaine	DB00976 telithromycin	the risk or severity of rmoderado
DB00807 propracaine	DB00978 lomefloxacin	the risk or severity of rmoderado
DB00807 propracaine	DB00994 neomycin	the risk or severity of rmoderado
DB00807 propracaine	DB01000 cycloclillin	the risk or severity of rmoderado
DB00808 indapamide	DB13791 penfluridol	the risk or severity of cgrave
DB00808 indapamide	DB14063 dextropropamyl	the risk or severity of cgrave
DB00808 indapamide	DB14568 ivosidenib	the metabolism of indmoderado
DB00808 indapamide	DB01227 levacetylmethadol	the therapeutic effica moderado
DB00808 indapamide	DB01242 clomipramine	clomipramine may de moderado
DB00808 indapamide	DB11718 encorafenib	the risk or severity of cgrave
DB00808 indapamide	DB01084 emedastine	the risk or severity of cgrave
DB00808 indapamide	DB15982 berotralstat	the metabolism of indmoderado
DB00808 indapamide	DB00883 isosorbide dinitrate	the risk or severity of rmoderado
DB00808 indapamide	DB01041 thalidomide	the risk or severity of cmoderado
DB00808 indapamide	DB01262 carbocisteine	the risk or severity of cmoderado
DB00808 indapamide	DB01612 amyl nitrite	the risk or severity of cmoderado
DB00808 indapamide	DB04899 nesiritide	the risk or severity of cmoderado
DB00808 indapamide	DB09077 dinutuximab	the risk or severity of cmoderado

Figura 3. Exemplo de amostras do dataset de interações medicamentosas.

E. Tratamento de Desbalanceamento

Será aplicada a técnica *class_weight*, permitindo maior penalização de erros nas classes minoritárias, melhorando a detecção de interações graves.

F. Avaliação dos Modelos

Os modelos serão avaliados com acurácia, precisão, recall e F1-score:

$$F1 = \frac{2 \cdot Preciso \cdot Recall}{Preciso + Recall}$$

Além disso, será utilizada validação cruzada (*k-fold*), garantindo maior robustez estatística. A matriz de confusão permitirá análise detalhada dos erros.

Também será realizada comparação entre modelos considerando desempenho médio e variância dos resultados, aumentando a confiabilidade das conclusões.

G. Viabilidade

O projeto é viável com uso de Python, scikit-learn e execução em Google Colab ou máquinas locais. A equipe possui experiência prévia nas tecnologias utilizadas.

III. ETAPAS DO PROJETO E MARCOS

O projeto será dividido nas seguintes etapas:

Estado da arte: revisão detalhada da literatura recente.

Tabela I
RESUMO DOS MATERIAIS E MÉTODOS

Categoria	Descrição	Observação
Dataset	DrugBank [1]	Base biomédica real
Modelos	RF, SVM, XGBoost	Classificação supervisionada
Técnicas	TF-IDF, class_weight	Processamento textual
Linguagem	Python	Implementação
Bibliotecas	scikit-learn, pandas	Machine Learning
Hardware	CPU/GPU	Execução dos experimentos

Dataset: limpeza, transformação e análise exploratória dos dados.

Modelos: treinamento, ajuste de hiperparâmetros e validação.

Experimentação: execução de testes controlados e validação cruzada.

Análise: comparação entre modelos e interpretação dos resultados.

Redação: elaboração do artigo científico.

IV. SCHEDULE

Tabela II
CRONOGRAMA DO PROJETO

Etapas	Semanas
Coleta de Dados - Download e análise do DrugBank	02/03–15/03
Pré-processamento - Limpeza, tratamento e criação de labels	16/03–29/03
Engenharia de Features - Representação textual (TF-IDF)	30/03–05/04
Treinamento dos Modelos - RF, SVM e XGBoost	06/04–19/04
Ajuste e Validação - Testes e validação cruzada	20/04–03/05
Avaliação - Métricas e análise	04/05–17/05
Escrita do Relatório - Redação final	18/05–31/05

V. LIMITAÇÕES

O uso de TF-IDF pode não capturar completamente o contexto semântico das interações. Além disso, modelos clássicos podem apresentar desempenho inferior a abordagens baseadas em deep learning.

Outra limitação envolve a dependência de regras heurísticas para classificação da severidade, o que pode introduzir viés.

VI. CONSIDERAÇÕES FINAIS

Espera-se identificar o modelo mais adequado para a classificação da gravidade das interações medicamentosas.

Os resultados poderão contribuir para sistemas de apoio à decisão clínica, auxiliando profissionais de saúde na prevenção de interações adversas.

Como trabalhos futuros, propõe-se a utilização de modelos baseados em deep learning, como BERT, além da integração da solução em sistemas reais.

REFERÊNCIAS

- [1] D. Wishart et al., “DrugBank: a comprehensive resource,” Nucleic Acids Research, 2018.
- [2] J. Esteva et al., “A guide to deep learning in healthcare,” Nature Medicine, 2019.
- [3] S. Zhang et al., “Drug-drug interaction prediction using machine learning,” 2024.

- [4] Y. Wang et al., “Multiple approaches for drug interaction extraction,” 2025.
- [5] J. Lee et al., “BioBERT: a pre-trained biomedical language model,” 2023.